# Spark 编程 & Spark SQL 李振安 151278019

### 一、环境配置

下载 Spark 2.2.1,并解压安装 配置环境变量,修改/etc/profile,添加 Spark 路径 修改 conf/spark-env.sh,添加 java 路径、Hadoop 路径 运行 pyspark

### 二、 代码说明

spark 编程,实现中文分词、统计词频、sparkSQL 语句查询使用两种方法过滤 1.使用 RDD 的 filter 方法过滤 2.使用 SQL 查询语句查询 输入格式 <input> <output> <k>

## 三、 Spark 编程 (Python)

return words

```
中文分词函数:
```

#中文分词

```
MapReduce:
#MapReduce
lines = spark.read.text(sys.argv[1]).rdd.map(lambda r: r[0])
counts = lines.flatMap(lambda x: chiwordsplit(x)) \
             .map(lambda x: (x, 1)) \
             .reduceByKey(add)\
             .sortBy(lambda x: -x[1])
使用 RDD 的 filter 方法过滤词频在 k 次以下的单词:
#使用RDD的filter方法过滤词频在k次以下的单词
Filteredcounts = counts.filter(lambda x: x[1] >= k)
output = Filteredcounts.collect()
Spark SQL:
#RDD 创建DataFrame
df = spark.createDataFrame(output, ['word', 'count'])
df.createOrReplaceTempView("wordlist")
#SQL Spark SQL查询统计结果中次数超过k次的词语
df2 = spark.sql("SELECT * from wordlist WHERE count > "+str(k))
#把查询结果输出到文件
SQLoutput=df2.collect()
f=open("SQL"+sys.argv[2],'w')
for (word, count) in SQLoutput:
    print("%s: %i" % (word, count))
    f.write(word+" : "+str(count)+"\n")
f.close()
   一些主要类的方法说明
```

## 四、

**map**(*f*, *preservesPartitioning=False*)

Return a new RDD by applying a function to each element of this RDD.

```
>>> rdd = sc. parallelize(["b", "a", "c"])
>>> sorted(rdd.map(lambda x: (x, 1)).collect())
[('a', 1), ('b', 1), ('c', 1)]
```

sortBy(keyfunc, ascending=True, numPartitions=None)

Sorts this RDD by the given keyfunc

```
\rightarrow \rightarrow \rightarrow  tmp = [('a', 1), ('b', 2), ('1', 3), ('d', 4), ('2', 5)]
\rightarrow \rightarrow \rightarrow sc. parallelize(tmp). sortBy(lambda x: x[0]). collect()
```

```
[('1', 3), ('2', 5), ('a', 1), ('b', 2), ('d', 4)]

>>> sc.parallelize(tmp).sortBy(lambda x: x[1]).collect()

[('a', 1), ('b', 2), ('1', 3), ('d', 4), ('2', 5)]
```

# filter(f)

Return a new RDD containing only the elements that satisfy a predicate.

```
>>> rdd = sc.parallelize([1, 2, 3, 4, 5])
>>> rdd.filter(lambda x: x % 2 == 0).collect()
[2, 4]
```